

Predicción de la prevalencia de depresión a nivel país-año

a partir de la prevalencia de otros trastornos mentales (IHME · GBD)

Valentina Giraldo · Aprendizaje de Máquina Aplicado · EAFIT · 2026

Modelo final: RF (tuneado) | RMSE = 0.618 [IC95% 0.597-0.638] | MAE = 0.517 | R² = 0.426 [IC95% 0.380-0.467]

sobre 41 países nunca vistos durante el entrenamiento — split por país, GroupShuffleSplit 80/20, SEED=42

1. Problema y datos

Tarea de regresión supervisada: estimar la prevalencia de depresión (share de población, estandarizado por edad) por país y año.

Dataset: Mental Illnesses Prevalence (IHME · GBD, vía Our World in Data). 6150 filas, 205 países, 1990-2019.

Se excluyen 9 agregados regionales del CSV original (Africa, Europe, EU27, grupos de ingreso) que no son países.

2. Metodología (CRISP-DM)

• Marco: CRISP-DM en 3 entregas acumulativas (problema/baseline → comparación de familias → modelo final) y el


• Split externo: GroupShuffleSplit 80/20 por Entity (164 / 41 países).

• Tuning: GridSearchCV con GroupKFold(5) por país sobre el train. Pipeline con StandardScaler para los modelos lineales.


• Métrica primaria: RMSE en puntos porcentuales del target. Complementarias: MAE y R².

• Validación complementaria: bootstrap (n=2000) sobre el test para IC95% y repetición con 5 semillas del split externo para medir robustez.


3. Resultado en test (41 países no vistos)




4. ¿Qué features explican la predicción?




5. Confianza del resultado (bootstrap)




6. Sensibilidad al split de países (5 semillas)




7. y real vs y predicho




8. Países con mayor error en test



9. Partial dependence — relación no lineal



10. Dos protocolos de validación dan respuestas distintas



11. Hallazgos clave

- Las prevalencias de los otros trastornos mentales Sí contienen señal predictiva sobre la depresión, pero la relación es NO LINEAL.
- La feature dominante es la prevalencia de esquizofrenia, seguida de ansiedad y bipolaridad. El año aporta casi nada.
- Generalizar a países nuevos ($R^2 \approx 0.43$) es más difícil que generalizar a años nuevos del mismo país ($R^2 \approx 0.83$). Son problemas de extrapolación.
- El modelo Random Forest con grid amplio supera ligeramente a HistGB en este split. El ensemble no aporta sobre RF sola.

12. Limitaciones explícitas

- ALTA sensibilidad al split externo: R^2 entre 0.16 y 0.58 según la semilla. Para uso real, reportar el rango sobre varias semillas.
- El target son estimaciones del IHME, no observaciones directas: el modelo aprende patrones de esa fuente.
- NO es inferencia causal. Que la esquizofrenia sea la feature más útil no implica que cause depresión.
- Núcleo persistente de países con error alto (Perú, Marruecos, Cuba, Alemania, Polonia). Las 5 features actuales no capturan suficiente contexto regional/socioeconómico.

13. Conclusiones y recomendaciones

El proyecto muestra que un Random Forest tuneado puede capturar la estructura no lineal de comorbilidad entre trastornos mentales a nivel país-año y mejorar sustancialmente al baseline lineal, alcanzando $R^2 = 0.426$ en 41 países nunca vistos. Para uso académico o exploratorio el modelo es utilizable como referencia comparativa entre perfiles de comorbilidad. Antes de pensar en despliegue, las acciones prioritarias son: (1) agregar features socioeconómicas (PIB per cápita, gasto en salud, urbanización) que probablemente cierren la brecha hasta $R^2 \approx 0.6+$; (2) reportar siempre el rango entre varias semillas y no un punto único; (3) validar fuera del IHME para descartar dependencia de la fuente. El modelo NO debe usarse para decisiones individuales: opera a nivel país-año.