

Entrega 1 — Problema, datos, EDA y baseline

Proyecto: Aprendizaje de Máquina Aplicado — EAFIT

Dataset: Mental Illnesses Prevalence (IHME / Our World in Data)

Entregable: Reporte PDF, notebook reproducible y data card

Marco metodológico: CRISP-DM

1. Problema y motivación

La salud mental es un componente esencial del bienestar humano y una carga sanitaria de gran magnitud: cientos de millones de personas experimentan trastornos mentales cada año. La medición poblacional a través de encuestas estandarizadas permite comparar países y periodos, aunque con limitaciones (sub-reporte, diferencias culturales y de memoria).

Pregunta planteada: ¿en qué medida la prevalencia de *depresión* de un país-año puede estimarse a partir de la prevalencia de los otros cuatro trastornos (esquizofrenia, ansiedad, trastorno bipolar y trastornos alimentarios) y el año? La respuesta cuantifica la estructura de comorbilidad a nivel poblacional y fija una referencia de dificultad para los modelos más elaborados que se compararán en la Entrega 2.


2. Data card

Campo	Valor
Fuente	IHME Global Burden of Disease — publicado por Our World in Data
Nombre del archivo	mental-illnesses-prevalence.csv
Filas totales	6420
Filas tras filtrar agregados	6150
Entidades únicas	214 (205 países + 9 agregados regionales)
Rango temporal	1990 – 2019 (30 años)
Variables	Entity, Code, Year + 5 shares de población con cada trastorno (estandarizadas por edad)
Unidad de observación	(país, año)
Tipo de tarea	Regresión supervisada
Variable objetivo	Depression (share de la población)
Features	schizophrenia, anxiety, bipolar, eating, Year
Missing	Solo en Code (9 agregados × 30 años = 270 filas); cero en numéricas
Limitaciones / riesgos	Datos basados en encuestas (sub-reporte); estimaciones modeladas (no observación directa); estru


3. Hallazgos del EDA

Se inspeccionó estructura, tipos, valores faltantes, distribuciones, correlaciones, tendencias temporales y relaciones bivariadas (guía del material 02_mla_eda.pdf). No hay faltantes en las variables numéricas; los 270 valores ausentes en *Code* corresponden a agregados regionales que se excluyen del análisis.


Distribución de prevalencias (1990–2019, nivel país)




Distribuciones: depresión y ansiedad presentan los rangos más amplios (2–7%); esquizofrenia y bipolar son mucho menos prevalentes y concentradas; trastornos alimentarios están sesgados a la derecha.




Correlaciones: la depresión muestra correlación moderada con ansiedad y bipolaridad; el año tiene correlación débil con todas las prevalencias, indicando cambios temporales graduales frente a la variabilidad entre países.



Tendencia temporal: la prevalencia media de cada trastorno es notablemente estable en el periodo 1990–2019, con ligeros movimientos; esto anticipa que el año explicará poca varianza del target.



Ranking (último año): se observan diferencias sustanciales entre países en prevalencia de depresión, lo que justifica el diseño de split por país (GroupShuffleSplit) y anticipa que modelos que capturen no-linealidades podrían mejorar el baseline.



Ansiedad vs depresión: relación positiva evidente, aunque con dispersión considerable, confirmando el valor predictivo moderado de la ansiedad sobre la depresión.

4. Definición formal del problema

Tarea: regresión supervisada.

Objetivo (y): *depression* — share de la población con trastorno depresivo.

Features (X): schizophrenia, anxiety, bipolar, eating, Year.

Unidad de observación: (país, año); 6150 filas tras excluir agregados.

Métrica principal: RMSE (en % de población). Se reportan también MAE y R^2 .

Estrategia de validación anti-fuga: GroupShuffleSplit por *Entity* (test $\approx 20\%$ de los países). Ningún país aparece a la vez en train y test. Se complementa con KFold 5-fold dentro del train para estimar variabilidad. Esta elección responde explícitamente la pregunta *¿el modelo generaliza a países no vistos?*, que es más exigente (y honesta) que un split aleatorio por filas.

5. Baseline reproducible — comparación de estrategias de split

Entrenamos dos baselines (**DummyRegressor** con media y **regresión lineal** con StandardScaler + LinearRegression en *Pipeline*) bajo dos particiones distintas para cuantificar el efecto del *data leakage* inducido por la estructura panel del dataset:

Split	Modelo	RMSE	MAE	R^2
(A) Aleatorio por fila (con fuga)	Dummy (media)	0.9670	0.7875	-0.0002
(A) Aleatorio por fila (con fuga)	LinReg escalada	0.8018	0.6060	0.3123
(B) Por país (sin fuga)	Dummy (media)	0.8285	0.7019	-0.0308
(B) Por país (sin fuga)	LinReg escalada	0.9141	0.6602	-0.2547

CV RMSE (KFold=5 en train): split aleatorio 0.778 ± 0.032 ; split por país 0.761 ± 0.026 . El split por país usa 164 países en train y 41 en test (4920 / 1230 filas).


Lectura clave: con el split aleatorio el modelo lineal *aparenta* funcionar muy bien porque los años del mismo país aparecen en train y test (fuga). Al separar por país, el modelo lineal cae por debajo del dummy: la mayor parte de la 'predicción' no era estructura generalizable sino memorización del nivel base de cada país. Esta comparación diagnóstica responde directamente a los requisitos de validación honesta de la rúbrica y marca el **listón real** que los modelos de la Entrega 2 deben superar.

5.1 Coeficientes estandarizados (modelo lineal, split aleatorio)


Feature	Coef. (escalado)
schizophrenia	-0.5440
anxiety	+0.2006
eating	+0.0894
Year	-0.0457
bipolar	+0.0307

La **ansiedad** es el predictor con mayor magnitud de coeficiente (consistente con la literatura sobre comorbilidad). El **año** aporta poca información, coherente con la estabilidad temporal observada en el EDA.

5.2 Diagnóstico de residuos



Residuos del split aleatorio (con fuga): estructurados pero centrados en cero.



Residuos del split por país (sin fuga): mayor dispersión y sesgo visible en ciertos rangos. Esta estructura no capturada motiva modelos no-lineales y features específicas por país/región.

6. Conclusiones preliminares

- Existe **señal real**: la regresión lineal reduce notablemente el RMSE frente al dummy cuando el split permite fuga por país.
- Sin embargo, bajo el split honesto por país, el baseline lineal **no** supera al dummy: la generalización a países nuevos es difícil para un modelo lineal global.
- La **ansiedad** es el predictor más informativo; el **año** aporta poco.
- Los residuos presentan heterocedasticidad y estructura remanente → modelos no-lineales (árboles, gradient boosting) y/o features por país tienen potencial de mejora.
- La comparación *row-split* vs. *country-split* fija una vara transparente para la Entrega 2.

7. Respuestas a las preguntas mínimas de la rúbrica

Pregunta	Respuesta
¿Qué problema intenta resolver?	Estimar la prevalencia de depresión de un país-año a partir de la prevalencia de los otros cuatro
¿Por qué este dataset es adecuado?	Limpio, con variable objetivo continua bien definida, tamaño manejable, estructura panel que o
¿Qué métrica es razonable y por qué?	RMSE (principal) porque está en las unidades del target, penaliza errores grandes y es directa
¿Cuál es el baseline y qué tan difícil parece ser (A) Dummy?	Baselinep (A) Dummy vs LinReg con split aleatorio → LinReg reduce ~17% el RMSE (RMSE=

8. Próximos pasos (Entrega 2)

Comparar al menos dos o tres familias: (i) lineales regularizados — Ridge, Lasso, ElasticNet; (ii) árboles / Random Forest; (iii) Gradient Boosting (XGBoost o LightGBM). Introducir GroupKFold por país, análisis temporal ($\text{train} \leq \text{año } t / \text{test} > t$), estudio de errores por región y primeras señales de interpretabilidad (permutation importance / SHAP).