

Entrega 2 — Comparación de familias y validación

Proyecto aplicado · Aprendizaje de Máquina Aplicado · EAFIT · 2026-04-30

Valentina Giraldo

Resumen ejecutivo

En esta entrega comparo tres familias de modelos para predecir la prevalencia de depresión a nivel país-año a partir de la prevalencia de los otros cuatro trastornos mentales del dataset IHME/GBD. Mantengo el problema, las features y el target definidos en la Entrega 1, y uso una validación sin fuga entre países (GroupShuffleSplit externo + GroupKFold interno). Los resultados muestran que los modelos basados en árboles (Random Forest y, sobre todo, **Histogram Gradient Boosting**) sí logran superar al dummy en países no vistos, mientras que las familias lineales se quedan por debajo. El mejor candidato obtiene $RMSE = 0.649$ y $R^2 = 0.368$ en test.

1. Problema y datos (recap)

Tarea de regresión supervisada: predecir *depression* (share de la población con trastorno depresivo, estandarizado por edad) a partir de *schizophrenia*, *anxiety*, *bipolar*, *eating* y *Year*. Tras excluir los 9 agregados regionales del CSV, trabajo con 6150 filas y 205 países entre 1990 y 2019. La métrica principal es **RMSE** (en puntos porcentuales del target), complementada por MAE y R^2 .

2. Metodología y protocolo de validación

Split externo: *GroupShuffleSplit* 80/20 por *Entity* (SEED=42). Entreno con 4920 filas / 164 países; reservo 1230 filas / 41 países para una única evaluación final.

Tuning interno: *GridSearchCV* con *GroupKFold*(5) por país sobre el train, *scoring*=neg_RMSE.


Evitar fuga: el escalado se hace dentro del *Pipeline*, así que cada fold ajusta el *StandardScaler* solo con su propio train. El test no se toca hasta el final.

Familias comparadas: (i) lineal regularizado — ElasticNet (α , *l1_ratio*); (ii) Random Forest (*n_estimators*, *max_depth*, *min_samples_leaf*); (iii) Histogram Gradient Boosting (*learning_rate*, *max_iter*, *max_depth*). Se incluye un *DummyRegressor* (media) y la *LinearRegression* de la Entrega 1 como referencias.

3. Resultados de validación cruzada

Modelo	RMSE CV (media)	$\pm$ std
Dummy (media)	0.9674	0.1126
LinReg (baseline)	0.7624	0.1986
ElasticNet	0.7617	0.1983
RandomForest	0.7723	0.1407
HistGB	0.7594	0.1331


Las tres familias entrenadas mejoran claramente al dummy en CV; entre ellas **HistGB** es la mejor ($RMSE \approx 0.76$), seguida de cerca por ElasticNet y del LinReg de Entrega 1. La desviación estándar entre folds es alta (0.13–0.20), lo que indica que algunos países son más difíciles de predecir que otros y el promedio depende mucho de la composición del fold.



4. Evaluación final en test (países no vistos)

Modelo	RMSE	MAE	R ²
Dummy	0.8285	0.7019	-0.0308
LinReg	0.9141	0.6602	-0.2547
ElasticNet	0.9051	0.6544	-0.2302
RandomForest	0.7505	0.6006	0.1541
HistGB	0.6489	0.5218	0.3677

HistGB obtiene $RMSE \approx 0.649$ y $R^2 \approx 0.368$ en países que no vio durante el entrenamiento. Random Forest también supera al dummy ($R^2 \approx 0.154$). Las familias lineales, incluso con regularización (ElasticNet), quedan por debajo del dummy ($R^2 < 0$): el sesgo del modelo lineal no logra absorber la heterogeneidad entre países.




5. Hiperparámetros seleccionados

Familia	Mejores hiperparámetros
ElasticNet	alpha=0.01, l1_ratio=0.9
RandomForest	max_depth=8, min_samples_leaf=1, n_estimators=300
HistGB	learning_rate=0.1, max_depth=6, max_iter=600

6. Análisis de errores


El gráfico de residuos muestra que los modelos lineales mantienen una banda inclinada característica (subestiman valores altos y sobrestiman bajos), mientras que la nube de residuos de los modelos de árboles se centra mejor alrededor de cero, aunque todavía con outliers. El listado de países con mayor MAE coincide en buena parte con casos extremos del EDA (perfiles atípicos en una o más prevalencias) y sugiere que añadir información regional o de grupo de ingreso podría mejorar el modelo en la Entrega 3.



7. Interpretabilidad (permutation importance)

Feature	Aumento RMSE	$\pm$ std
schizophrenia	0.4557	0.0157
anxiety	0.2430	0.0111
bipolar	0.0802	0.0089
eating	0.1045	0.0054
Year	0.0038	0.0024

Sobre el modelo ganador (HistGB), la feature con mayor impacto al permutarse es la **prevalencia de esquizofrenia** (+0.456 de RMSE), seguida de la **ansiedad** (+0.243). Las demás aportan menos y el **año** es prácticamente irrelevante. Este resultado coincide con el orden de magnitud de los coeficientes estandarizados del baseline lineal de la Entrega 1, aunque no con la correlación marginal observada en el EDA (donde la ansiedad parecía el predictor más fuerte): es un buen recordatorio de que la importancia marginal y la importancia condicional pueden no coincidir.



8. ¿Desbalance o ajuste de umbral?

Estos análisis pertenecen al universo de la clasificación. Como el problema aquí es de regresión sobre un share continuo, no aplica desbalance de clases ni ajuste de umbral. El equivalente relevante para regresión es el **sesgo del target**: el target está sesgado a la derecha y un puñado de países concentra los valores más altos. Por eso reporto tanto RMSE (más sensible a esos extremos) como MAE (más robusto). La diferencia entre RMSE y MAE del modelo ganador (0.649 vs 0.522) confirma que hay pocos países con errores grandes que elevan el RMSE; el listado del top-15 los identifica.

9. Conclusión provisional y limitaciones

Decisión provisional: el modelo más prometedor es *HistGradientBoostingRegressor*. Es el único que supera de forma clara al dummy en países no vistos (con un margen significativo) y mantiene una buena interpretabilidad vía permutation importance. La regularización lineal no fue suficiente para cerrar la brecha de Entrega 1.

Limitaciones abiertas: (i) un subconjunto de países concentra el error y podría beneficiarse de features regionales o de grupo de ingreso; (ii) no se ha probado una validación temporal estricta (train hasta año t , test después), que sería el escenario más realista para predicción prospectiva; (iii) el grid de hiperparámetros es modesto: tuneos más finos o stacking podrían mover el resultado. Estos puntos quedan como agenda para la Entrega 3.