

Resumen ejecutivo

Predicción de la prevalencia de depresión a nivel país-año a partir de la prevalencia de otros trastornos mentales (IHME · GBD)

Proyecto aplicado · Aprendizaje de Máquina Aplicado · EAFIT · Valentina Giraldo · 2026-05-14

Problema

Estimar la prevalencia de depresión (% de la población, estandarizada por edad) a nivel país-año, con información de la prevalencia de esquizofrenia, ansiedad, trastorno bipolar y trastornos alimentarios. Datos: *Mental Illnesses Prevalence* (IHME · GBD), 6150 filas, 205 países, 1990-2019.

Resultado clave

Métrica	Valor	IC95% (bootstrap, n=2000)
RMSE	0.618	[0.597, 0.638]
MAE	0.517	[0.498, 0.536]
R ²	0.426	[0.380, 0.467]

Modelo final: RF (tuneado) (n_estimators=800, max_depth=8, min_samples_leaf=3, max_features='sqrt'), tuneado con GroupKFold(5) por país. Evaluación final en 41 países nunca vistos. Supera al baseline lineal de la Entrega 1 (que daba $R^2 < 0$ con el mismo split por país) y al dummy de la media.

Hallazgos

- **La señal es no lineal.** La regresión lineal (Entrega 1) no podía generalizar a países nuevos; los modelos basados en árboles sí lo logran porque capturan respuestas con tramos.
- **La feature más informativa es la prevalencia de esquizofrenia** (permutation importance ≈ 0.28 de RMSE; ablación: +0.09 al quitarla). Le siguen ansiedad y bipolaridad. El año aporta casi nada.
- **El año aporta casi nada:** la prevalencia estandarizada por edad cambia poco en 30 años. La señal está en la *estructura transversal* de comorbilidad, no en su evolución temporal.
- **Generalizar a países nuevos es más difícil que generalizar a años nuevos del mismo país.** En split temporal estricto (train ≤ 2009 / test 2010-2019) el R^2 sube a 0.828 porque el modelo interpola años, no extrapola países.

Limitaciones que afectan el uso del modelo

- **Alta sensibilidad al split.** Con 5 semillas distintas el R^2 varía entre 0.16 y 0.58. El número del recuadro corresponde a SEED=42; para una decisión real conviene reportar promedio sobre semillas y su rango.
- **Datos del IHME, no observaciones directas.** El target son estimaciones suavizadas por modelos epidemiológicos. El modelo aprende patrones de esa fuente, no de mediciones brutas.
- **No es inferencia causal.** Que *schizophrenia* sea la feature más útil para predecir *depression* en este modelo **no implica** que la cause; las prevalencias se mueven juntas porque comparten determinantes sociales no observados.
- **Núcleo persistente de países con error alto:** Perú, Marruecos, Cuba, Alemania, Polonia. Las 5 features no capturan suficiente contexto regional o socioeconómico.

Recomendaciones

1. **Para uso académico o exploratorio:** el modelo es utilizable como referencia para comparar perfiles de comorbilidad entre países. Reportar siempre el intervalo, no solo el punto.
2. **Antes de pensar en despliegue:** agregar features socioeconómicas (PIB per cápita, gasto en salud, urbanización) para subir el R^2 de ~ 0.4 a $0.6+$ y validar con varias semillas.
3. **No usar para decisiones individuales:** el modelo opera a nivel país-año, no a nivel persona.

