

Predicción de la prevalencia de depresión

a nivel país-año (IHME · GBD)

Entrega 3 — Modelo final, interpretación y comunicación

Valentina Giraldo

Aprendizaje de Máquina Aplicado · EAFIT · 2026

1. Problema y datos


Tarea: regresión supervisada a nivel país-año

Predecir la prevalencia de depresión
(share de población, estandarizado por edad)

- Features:
- schizophrenia
 - anxiety
 - bipolar
 - eating
 - Year

Dataset: Mental Illnesses Prevalence
(IHME · Global Burden of Disease,
vía Our World in Data)

6150 filas
205 países
1990–2019




2. Metodología

CRISP-DM, sin fuga entre países

- Split externo: GroupShuffleSplit 80/20 por país (SEED=42)
 - 164 países train · 41 países test (nunca vistos)
- Tuning interno: GridSearchCV con GroupKFold(5) por país
 - cero leakage entre folds; StandardScaler dentro del Pipeline
- Familias re-evaluadas en Entrega 3:
 - HistGradientBoosting (grid amplio + early stopping)
 - Random Forest (grid amplio)
 - Ensemble por promedio HistGB + RF
- Validación complementaria:
 - Bootstrap (n=2000) sobre el test → intervalos de confianza
 - 5 semillas distintas del split externo → sensibilidad
 - Split temporal estricto (train ≤ 2009 / test 2010–2019)
- Métrica primaria: RMSE en puntos porcentuales del target
 - Complementarias: MAE (robusta) y R^2 (intuitiva)

3. Comparación en test y decisión del modelo final

41 países que el modelo no vio nunca



Modelo final:
RF (tuneado)

RMSE = 0.618

MAE = 0.517



$R^2 = 0.426$

El ensemble no aporta sobre RF sola. HistGB queda en 2º.

Mejora claramente al dummy y al LinReg de la Entrega 1 ($R^2 < 0$ con el mismo split).

4. ¿Qué tan confiable es el resultado?




Bootstrap (n=2000) + sensibilidad a la semilla del split



Bootstrap: estrecho (IC95% RMSE $\approx$ [0.60, 0.64]). Pero entre semillas: R^2 varía entre 0.16 y 0.58 — esta es la limitación principal.

5. ¿Qué features explican la predicción?



Permutation importance + partial dependence



Feature dominante: prevalencia de esquizofrenia. Relación NO lineal. El año aporta casi nada.

6. Dónde falla el modelo + dos protocolos de validación

El núcleo de error coincide con outliers del EDA



Países pesados: Perú, Marruecos, Cuba, Alemania, Polonia. Split temporal: R^2 0.83 — más fácil porque interpola años, no extrapola países.

7. Conclusiones y recomendaciones

Lo que funciona:

- Los modelos basados en árboles sí capturan la estructura no lineal de comorbilidad entre trastornos.
- RF final: $R^2 = 0.426$ en países nuevos. Salto claro sobre el dummy y el baseline lineal de Entrega 1.
- La feature dominante es la prevalencia de esquizofrenia (no causal, contextual).
- El año aporta casi nada.

Limitaciones honestas:

- R^2 varía entre 0.16 y 0.58 según la semilla. Reportar el rango, no el punto.
- Target son estimaciones del IHME, no observaciones directas.
- No es inferencia causal.

Próximos pasos:

- Agregar features socioeconómicas → probablemente $R^2 \sim 0.6+$.
- Validación cruzada por región.
- Intervalos de predicción explícitos.