

Entrega 3 — Modelo final, interpretación y comunicación

Predicción de la prevalencia de depresión a nivel país-año a partir de la prevalencia de otros trastornos mentales (IHME · GBD).

Proyecto aplicado · Aprendizaje de Máquina Aplicado · EAFIT · 2026-05-14

Valentina Giraldo

Resumen ejecutivo

Este proyecto resuelve una tarea de regresión supervisada: estimar la prevalencia de depresión (share de la población, estandarizado por edad) a nivel país-año, a partir de la prevalencia de los otros cuatro trastornos mentales del dataset IHME/GBD y del año. Tras tres iteraciones (CRISP-DM), el modelo final es un **Random Forest tuneado con GroupKFold(5) por país**. Sobre 41 países nunca vistos durante el entrenamiento, alcanza **RMSE = 0.618** (IC95% [0.597, 0.638]), **MAE = 0.517** y **R² = 0.426** (IC95% [0.380, 0.467]). Mejora claramente al dummy y al baseline lineal de la Entrega 1, y la prevalencia de esquizofrenia resulta ser la feature más informativa. El proyecto deja como limitación principal la **alta sensibilidad al split de países**: el R² varía entre 0.16 y 0.58 según qué 41 países caen en test.

1. Problema y datos

Pregunta: ¿se puede predecir la prevalencia de depresión a nivel país-año a partir de la prevalencia de otros trastornos mentales? **Tarea:** regresión supervisada. **Target:** *depression* (prevalencia, share de la población). **Features:** *schizophrenia, anxiety, bipolar, eating, Year*. **Unidad de observación:** par (país, año). Tras excluir los 9 agregados regionales del CSV (Africa, Europe, EU27, grupos de ingreso, etc.) trabajo con 6150 filas y 205 países entre 1990 y 2019. La **métrica principal es RMSE** en puntos porcentuales del target, complementada por MAE (más robusto a outliers) y R² (lectura intuitiva). La elección del dataset y del target se justificó en la Entrega 1.

2. Metodología y protocolo

Marco metodológico: CRISP-DM (Entrega 1 = comprensión + datos + baseline; Entrega 2 = comparación de familias; Entrega 3 = modelo final, interpretación y comunicación).

Split externo: *GroupShuffleSplit* 80/20 por *Entity* con SEED=42 (heredado de Entregas 1 y 2). Entreno con 4920 filas / 164 países; test con 1230 filas / 41 países nunca vistos hasta la evaluación final.

Tuning interno: *GridSearchCV* con *GroupKFold(5)* por país sobre el train, scoring = neg_RMSE. Cada candidato se entrena dentro de un *Pipeline* para evitar fuga entre folds.

Familias re-evaluadas en Entrega 3: HistGradientBoosting (grid amplio + early stopping), Random Forest (grid amplio) y Ensemble por promedio de los dos. Como referencia se mantiene la comparación con el Dummy y el LinReg de la Entrega 1.

Validación adicional: bootstrap de 2000 muestras del test para calcular intervalos de confianza, repetición con 5 semillas distintas del split externo para medir sensibilidad y un split temporal estricto (train 1990-2009 / test 2010-2019) como protocolo alternativo.

3. Tuning final de las familias candidatas


Familia	CV-RMSE	± std	Mejores hiperparámetros
HistGB	l2_regularization=0.73021, learning_rate=0.03	0.13714	max_depth=4, max_iter=500, min_samples_leaf=20

RF	0.7184	0.1295	max_depth=5, max_features=sqrt, min_samples_leaf=3, n_estimators=800
----	--------	--------	--

Con el grid ampliado, el CV-RMSE de HistGB pasa de 0.76 (Entrega 2) a 0.732 y el de RF de 0.77 a 0.718. La mejora del RF es mayor: indicaría que el grid corto de la Entrega 2 estaba lejos de su óptimo. Ambas familias siguen mostrando std de CV alta (≈ 0.13), confirmando que el desempeño promedio entre folds esconde heterogeneidad fuerte entre países.

4. Evaluación final en test


Modelo	RMSE	MAE	R ²
HistGB (tuneado)	0.6421	0.5002	0.3808
RF (tuneado)	0.6180	0.5168	0.4264
Ensemble (HistGB+RF)	0.6186	0.5000	0.4253



Decisión: el modelo final es **RF (tuneado)**, por menor RMSE en test. La diferencia con HistGB es pequeña pero consistente, y el ensemble por promedio no aporta más que RF sola.

5. Confianza del resultado — bootstrap


Métrica	Valor	IC95% inf.	IC95% sup.
RMSE	0.6180	0.5974	0.6380
MAE	0.5168	0.4979	0.5357
R2	0.4256	0.3799	0.4668



Con 2000 remuestras del test, el intervalo de confianza al 95 % del RMSE es estrecho ([0.597, 0.638]). El R² se ubica con confianza por encima de 0 (el dummy daría 0). Eso significa que, *dentro* de este split de países, el resultado es estadísticamente robusto.

6. Sensibilidad al split externo


Seed	RMSE	MAE	R ²
0	0.5716	0.4363	0.5131
1	0.7441	0.5553	0.5817
7	0.9344	0.7333	0.2367
21	0.6655	0.5038	0.1570
42	0.6421	0.5002	0.3808



Esta es la limitación más fuerte del proyecto. Re-entrenando el modelo con los mismos hiperparámetros sobre 5 semillas distintas del split externo, el R² varía entre **0.16 y 0.58** y el RMSE entre **0.57 y 0.93**. Con 205 países y solo 5 features, el resultado depende fuertemente de qué subconjunto cae como test. Para un uso real habría que reportar la *distribución* de métricas sobre varias semillas, no un solo punto. El número que reporto en el resumen (R² ≈ 0.43) es el caso de SEED=42 — el mismo que vengo usando desde la Entrega 1 por consistencia, pero no es la performance esperada en cualquier conjunto de 41 países nuevos.

7. Validación alternativa: split temporal


Protocolo	n_train	n_test	RMSE	MAE	R ²
Por país (final)	4920	1230	0.6180	0.5168	0.4264
Temporal 1990-2009 / 2010-2019	4100	2050	0.3803	0.2722	0.8279




El split temporal **parece mucho mejor** ($R^2 \approx 0.83$), pero hay que leerlo con cuidado: aunque no se repite ningún par (país, año), el train contiene años previos del mismo país, y la prevalencia estandarizada por edad varía poco año a año. El modelo no extrapola a países nuevos, interpola años nuevos. Son dos preguntas distintas y ambas son legítimas, pero la honesta para una recomendación de salud pública en países pobremente representados en GBD es la del split por país ($R^2 \approx 0.43$), no la temporal.

8. Interpretabilidad

Feature	Aumento RMSE	$\pm$ std
schizophrenia	0.2821	0.0126
anxiety	0.0831	0.0053
bipolar	0.0684	0.0067
eating	0.0190	0.0037
Year	-0.0003	0.0002




La feature más informativa es la **prevalencia de esquizofrenia** (+0.282 de RMSE al permutarla), seguida de **ansiedad** (+0.083) y **bipolaridad** (+0.068). El **año** es prácticamente irrelevante (importancia centrada en cero). Este orden es estable entre las semillas que probé.



Las curvas de *partial dependence* sobre las dos features principales muestran que la relación de *schizophrenia* con la predicción **no es lineal**: el modelo aprende una respuesta con tramos planos y un tramo creciente. La *anxiety* sigue una respuesta cercana a lineal y monótona. Esto explica por qué el modelo lineal de la Entrega 1 era insuficiente.

9. Análisis de sensibilidad por ablación


Feature removida	RMSE	Δ RMSE
(ninguna — baseline)	0.6421	0.0000
schizophrenia	0.7340	0.0919
anxiety	0.6891	0.0470
bipolar	0.6576	0.0155
eating	0.6689	0.0268
Year	0.6227	-0.0194




Quitar *schizophrenia* es lo que más empeora el modelo (+0.092 de RMSE), confirmando que su contribución no es redundante con las otras features. Quitar *Year* mejora levemente, lo que sugiere que aporta más ruido que señal — consistente con la baja permutation importance. Las demás features aportan moderadamente.

10. Análisis de errores

Los residuos en test no muestran sesgo sistemático (la media de residuos está cerca de cero) pero sí tienen colas: hay un grupo de países con error sustancial. Los identifico abajo.





El listado del top 10 incluye Peru, Morocco, Germany, Poland, Cuba, Lesotho, Honduras, South Africa, Ukraine, United States. Son una mezcla de países con perfil epidemiológico atípico (Perú, Marruecos, Cuba — ya identificados como outliers en el EDA de la Entrega 1), países europeos con depresión alta pero comorbilidades moderadas (Alemania, Polonia, Portugal) y países pequeños con estimaciones más ruidosas en GBD (Saint Kitts and Nevis, Lesotho). Esto sugiere que las 5 features actuales no capturan suficiente información de contexto regional/socioeconómico.

11. Discusión y respuestas a la rúbrica

¿Cuál es el mejor modelo y por qué?

RF (tuneado) con `max_depth=8`, `max_features=sqrt`, `min_samples_leaf=3`, `n_estimators=800`. Tiene el menor RMSE en test (por encima de HistGB tuneado y del ensemble), es robusto sin necesitar early stopping ni regularización explícita, y el ensemble HistGB+RF no mejora sobre RF sola. La elección del baseline lineal de la Entrega 1 quedó descartada por su incapacidad de capturar la relación no lineal de *schizophrenia* con la prevalencia de depresión.

¿Qué tan confiables son sus resultados?

Dentro del split fijado el resultado es robusto: bootstrap ($n=2000$) da $RMSE = 0.618$ con IC95% [0.597, 0.638] y $R^2 = 0.426$ con IC95% [0.380, 0.467]. **Entre splits** el resultado es mucho más variable: el R^2 entre 5 semillas distintas varía entre 0.16 y 0.58. Para una decisión real habría que reportar el promedio sobre varias semillas y su rango.

¿Qué variables o patrones explican el desempeño?

La señal principal está en la **estructura transversal de comorbilidad** entre los cuatro trastornos mentales. La feature dominante es *schizophrenia*, con una relación no lineal respecto al target. *Anxiety* y *bipolar* aportan un nivel intermedio. El *año* es prácticamente irrelevante: la prevalencia estandarizada por edad cambia muy poco en 30 años. Lo importante epidemiológicamente es *qué tan comórbidos* son los trastornos en un país, no en qué año estamos.

¿Qué conclusiones útiles deja el proyecto?

1) Las prevalencias de otros trastornos mentales **sí contienen información predictiva** sobre la prevalencia de depresión a nivel país, pero la relación es no lineal y la familia lineal no la captura. 2) La generalización a **países nuevos** es limitada ($R^2 \approx 0.43$), pero la generalización a **años nuevos del mismo país** es alta ($R^2 \approx 0.83$). Son problemas distintos. 3) Hay un núcleo persistente de países donde el error es alto; con las 5 features actuales no se explican.

¿Qué haría falta para mejorar o desplegar?

Features: añadir indicadores socioeconómicos (GDP per cápita, gasto en salud, urbanización, índices de equidad) probablemente mueva el R^2 de ~ 0.4 a $0.6+$. **Modelado:** probar enfoques jerárquicos que respeten la estructura país/región/grupo de ingreso. **Validación:** reportar promedio sobre varias semillas y validación cruzada por región. **Despliegue:** intervalos de predicción explícitos (cuantiles de RF), alertas si los inputs de un país nuevo caen fuera del rango aprendido, y monitoreo de drift al actualizar el GBD anualmente.

12. Limitaciones explícitas

- 1) El target son **estimaciones del IHME**, no observaciones directas; ya están suavizadas por sus modelos epidemiológicos. Cualquier patrón aprendido por mi modelo es relativo a esa fuente.
- 2) Las 5 features capturan solo la **comorbilidad entre trastornos**; no incluyen variables sociales, económicas ni de sistema de salud.
- 3) El resultado **depende del split** de países (R^2 entre 0.16 y 0.58 según la semilla). No es la limitación del modelo, sino del tamaño del dataset (205 países).
- 4) **No estoy haciendo inferencia causal**. Decir que *schizophrenia* es la feature más importante **no implica** que cause depresión; es la variable que más reduce el error en este modelo concreto sobre estos datos concretos.
- 5) **No hay validación geográfica fuera del IHME**: si las prevalencias estimadas por otra fuente (encuestas nacionales, p.ej.) fueran sistemáticamente distintas, el modelo no se transferiría sin calibración.

13. Reproducibilidad

Todo el proyecto es reproducible end-to-end. Semilla fija **SEED=42**. Para regenerar la Entrega 3:

```
cd project
pip install -r requirements.txt
python src/build_entrega3.py # experimentos + figuras + JSON
python src/build_notebook_entrega3.py # regenera el notebook
python src/build_pdf_entrega3.py # regenera este PDF
```

El detalle del checklist de reproducibilidad está en *report/reproducibility_checklist.md*.